

▼ SwiFT v2 최종 통합 논문 전략서 (v2.3)

가제: A Universal Foundation Model Bridging Spatiotemporal Brain Dynamics and Clinical Precision (부제: **From Scale-free Dynamics to Personalized Prognosis**)

--

1. 핵심 포지셔닝 (Core Positioning): The Bio-Clinical Alignment & Resolution

기존의 "Engineering Contest(성능/효율 경쟁)" 프레임을 넘어, "**생물학적 정합성 (Biological Fidelity)**"을 기반으로 "**임상적 필수성(Clinical Necessity)**"을 달성한다는 새로운 인과관계를 설정합니다. 여기에 "**데이터 표현의 해상도(Resolution)**" 차원을 더해 경쟁 모델들을 압도합니다. 또한, 우리 연구진의 **SwiFT v1**이 이 분야의 **First Mover**임을 명확히 합니다.

A. The Paradigm Shift (프레임 전환)

- The Old Frame (Competitors):

- **BrainLM (Low-Res ROI)**: 뇌를 424개의 단어(ROI)로 단순화하여 계산 효율을 얻었으나, **공간적 위상(Topology)**과 **국소적 미세 패턴**을 상실함,,.
- **NeuroSTORM (Efficiency-First)**: 4D 처리를 시도했으나, 효율성을 위해 Mamba를 채택함으로써 뇌의 **전역적 연결성(Global Connectivity)** 계산의 명시성을 희생함,.
- **Brain-JEPA (Noise Avoidance)**: 노이즈를 피하기 위해 복원 (Reconstruction)을 포기하여, 생성형 모델의 핵심인 **미래 상태 예측 (Forecasting)** 능력을 잃음,.

- The New Frame (SwiFT v2):

- **Biological Compliance**: 뇌 신호 고유의 **1/f 역동성(Pink Noise)**과 장기 기억(**Hurst Exponent**)을 보존하는 유일한 모델.
- **High-Resolution 4D**: ROI로 타협하지 않고 4D Voxel을 직접 처리하여 해부학적 구조(Anatomy)를 온전히 보존.
- **Clinical Necessity**: 위 두 가지 특성 덕분에, 단순 진단을 넘어 **예후 (Prognosis)**와 **치료 반응**을 예측하는 필수적 임상 도구가 됨.

B. The Heritage (SwiFT v1의 계승과 진화)

- **SwiFT v1 (The Pioneer):** 우리는 선행 연구(SwiFT v1)를 통해 세계 최초로 **4D fMRI를 Transformer로 직접 처리(End-to-End)**하는 아키텍처를 제안하고, ROI 방식 대비 우수성을 입증했음,. 이는 4D 처리의 '**가능성(Feasibility)**'을 연 연구였음.
 - **SwiFT v2 (The Standard):** v1이 가능성을 열었다면, v2는 **생성형 학습(MAE)**과 **Factorized Attention**을 통해 이를 '**파운데이션 모델(Universality)**'로 완성함. v1의 Contrastive Learning(구별 중심)을 넘어, v2는 뇌의 물리적 역동성 자체를 학습함.
-

2. 서론 (Introduction): 논리 전개 전략

[Paragraph 1: The Epistemic Gap - 뇌 데이터의 본질]

- 뇌는 정적인 이미지가 아니며, 단순한 단어의 나열(Sequence)도 아님. 뇌는 밀리초 단위의 미세한 시간적 흐름과 영역 간의 동적 상호작용으로 이루어진 **고해상도 시공간 복잡계(High-Res Spatiotemporal System)**임,.

[Paragraph 2: The Competitor Critique - 기존 접근의 한계]

- **Low-Resolution의 한계 (vs BrainLM):** BrainLM 등은 뇌를 수백 개의 ROI로 평균화함. 이는 마치 "**교향곡을 악보 없이 몇 개의 음표 평균값으로만 듣는 것**"과 같아서, 뇌 질환의 초기 징후인 미세한 국소적 변화를 놓칠 수밖에 없음,.
- **Non-Generative의 한계 (vs Brain-JEPA):** Brain-JEPA는 노이즈를 피하기 위해 복원을 포기했으나, 이는 뇌의 시간적 흐름을 예측하는 능력을 제한함,.

[Paragraph 3: Our Solution - The Evolution of SwiFT]

- **Heritage (SwiFT v1):** 우리 연구진은 SwiFT v1을 통해 4D Voxel-based Transformer가 fMRI 분석에 가장 적합함을 최초로 증명한 바 있음,.
- **Evolution (SwiFT v2):** SwiFT v2는 v1의 4D 처리 철학을 계승하되, Foundation Model로의 확장을 위해 핵심적으로 진화함:
 1. **Architecture:** 4D Window를 **Time-Space Factorized Attention**으로 재 설계하여 연산 효율과 Global Context 포착 능력을 동시에 극대화.
 2. **Embedding:** Absolute PE 대신 **RoPE**를 도입하여 가변적 시퀀스 처리에 유연성 확보.

3. **Scientific Validity: PSD($1/f$)와 Hurst Exponent** 분석을 통해 모델이 '뇌의 물리 법칙'을 내재화했음을 증명.
-

3. 결과 (Results): Engineering, Science, and Clinic의 조화

Part 1. Foundation Model로서의 자격 증명 (Scalability & Emergence)

▼ Part 1-1. 통합 지표(Unified Error Rate)와 Scaling Law:

- AUC와 MSE를 '**Unified Error Rate**'로 변환하여, 데이터 및 모델 크기 증가에 따른 성능 향상을 직관적으로 제시. SwiFT v1이 소규모 데이터에서 효율성을 증명했다면, v2는 초대규모 데이터에서의 확장성을 입증함,.
- **접근:** UKB 단일 데이터셋을 활용하여 Model Size, Data Size, Compute Budget의 3가지 축에서 Scaling Law를 검증합니다 9.
- **통합 지표 (Normalized Error Rate):** Classification(AUC)과 Regression(MSE)을 단일 지표인 'Error Rate'로 통일하여 직관적으로 제시합니다.
 - AUC 변환: $(1-AUC) * 2$ (0.5~1.0 → 0~1.0 Error).
 - MSE 변환: $RMSE / (max-min)$ (Min-Max Scaling).
- **Pre-train Loss의 가치:** Pre-train Loss가 낮아질수록 Downstream Task의 Error Rate가 감소함을 보여주어, Loss 지표의 신뢰성을 확보합니다.

▼ Part 1-2. Emergence (창발성):

- 대규모 데이터(ABCD, UKB, HCP) 학습 반복(Iteration)이 진행됨에 따라, 임베딩 공간에서 **Sex, Age**뿐만 아니라 **Scanner/Site Effect** 같은 미세한 변수들이 스스로 구분되는 현상(Cluster)을 t-SNE 등으로 시각화합니다.

▼ Part 1-3. 뇌 역동성의 과학적 증명 (Scientific Validity):

- "Brain-JEPA의 '노이즈' 비판을 '물리학'으로 반박하다"
- 주파수 도메인 분석 ($1/f$ Scale-free Dynamics):

- **결과:** Raw fMRI 신호는 $P \propto 1/f\beta$ 관계(Pink Noise)를 보임. SwiFT v2의 임베딩은 이 기울기(β)와 정확히 일치함,.
- **의의:** Brain-JEPA는 생성형 모델이 노이즈(White Noise)를 학습한다고 비판하지만, 우리는 노이즈는 거르고 **신경 역동성(Neural Dynamics)**만 학습했음을 입증.
- **시간적 지속성 (Hurst Exponent, H):**
 - **결과:** fMRI의 전형적인 범위인 $H \approx 0.7 \sim 0.9$ (Long-term Memory)**가 임베딩에서도 유지됨,.
 - **의의:** 윈도우 단위(40 frames) 처리에도 불구하고 시계열의 끊김 없이 **장기적인 문맥**이 보존됨을 수학적으로 증명. 이는 Mamba(NeuroSTORM)나 ROI 모델이 보여주지 못한 결과임.

Part 2. Comprehensive Evaluation on Downstream Tasks (The Generalist)

목표: 역사상 최초로 다양한 도메인을 아우르는 'Generalist Model'임을 입증

- **전략:** 특정 Task만 잘하는 기존 모델들과 달리, **4대 축(Pillars)** 모두에서 SOTA를 달성했음을 **Radar Chart** 등을 통해 시각적으로 압도합니다.
- **의의:** 비용 문제로 직접적인 임상 비교가 어려운 상황에서, 이 광범위한 평가 결과가 "임상적 유용성(Clinical Utility)"과 "데이터 빈곤(Data Scarcity) 해결 능력"을 대변합니다.
- **4대 검증 영역 (The 4 Pillars):**
 1. **Neurodegenerative:** MCI to AD Conversion (ADNI) - 미세한 병리 변화 감지
 2. **Psychiatric:** OCD (SNUH), MDD (Kim et al.), Antidepressant Response - 진단 및 예후 예측
 3. **Cognitive:** Attention (YooAttn), GradCPT, MOT, VSTM, Fluid Reasoning - 동적 인지 기능 추적
 4. **Functional:** Pain-evoked state (ToPS) - 신체 상태 예측

Part 3. 심층 분석: Post-hoc Analysis & Mechanism Discovery (Interpretability)

"성능 과시"가 목적이 아닙니다. "왜 우리 모델이 다른 모델에 비해서 좋은 성능을 보이는지(Why our model is superior), 그리고 성공적인 예측이 일어날 때(When the model works) 뇌의 어떤 정보를 사용하는지 규명"하기 위해 분석을 진행함.

▼ Part 3-1: Why our models work better?

- Part 1에서 사용하였던, Power Spectral Density (PSD)와 Hurst exponent를 활용하여, 베이스라인 모델들과 우리 모델을 비교.
- 우리 모델의 성능이 여타 베이스라인 모델에 비해 상당히 우위에 있었는데, PSD와 Hurst exponent를 통한 분석을 진행했을 때, "우리 모델의 임베딩이 resting-state fMRI 데이터의 pink noise의 특성을 잘 보존하면서도, raw 데이터의 Hurst exponent 분포와 가장 유사했다. 이는 우리 모델이 뇌의 시계열적 문맥(Temporal Context)을 가장 정확하게 이해하고 압축하고 있다는 강력한 정량적 증거이다 라는 점을 강조"
- 이를 통해 다음의 강점을 살려서 reviewer들을 공략:
 1. **"Black Box" 해소:** 딥러닝 모델이 왜 성능이 좋은지 단순히 '결과'만 보여주는 것이 아니라, PSD와 Hurst라는 신경과학적 지표를 통해 그 내부 원리를 설명하므로 신뢰도가 급상승합니다.
 2. **모델의 차별성 부각:** BrainLM이나 Brain-JEPA 같은 모델들이 왜 우리 모델보다 성능이 낮은지를 "시계열 정보의 파괴" 혹은 "아티팩트 학습"이라는 구체적인 이유로 지적할 수 있습니다.
 3. **Foundation Model의 가치:** "우리 모델은 뇌 영상을 단순히 처리하는 것이 아니라, 뇌의 물리적 법칙을 이해하는 수준까지 학습했다"는 메시지를 전달할 수 있습니다.

▼ Part 3-2: Clinical implication

- **Anatomical Validity (In-silico Functional Lesioning)**
 - **방법:** 주요 뇌 네트워크(DMN, Visual, Salience 등)를 가상으로 손상(Lesion)시켰을 때 성능 하락폭을 측정합니다²¹.
 - **가설 검증:**
 - MCI → AD: **기억 회로(DMN, Limbic)**의 중요도가 높게 도출되어야 함.
 - OCD/MDD: **인지 조절 회로(Frontoparietal, Salience)**의 중요도가 확인되어야 함.
 - **결론:** 모델이 질환의 **핵심 병변(Core Pathology)**을 정확히 타격하고 있음을 증명합니다.

- **Clinical Validity (Biotyping & Precision Medicine)**
 - **방법:** Linear Head 통과 전, 임베딩 공간(Latent Space)에서 환자군을 분석(RSA/Clustering)합니다.
 - **핵심 발견:** Baseline fMRI만으로 **항우울제 반응군(Responder) vs 비반응군(Non-responder)**이 임베딩 공간에서 명확히 분리됨을 시각화합니다.
 - **Literature Alignment:** 모델이 찾아낸 Subtype(하위 유형)이 기존 뇌과학 문헌에서 제시한 가설(예: 무쾌감증 vs 불안형)과 정합함을 보여주어 생물학적 타당성을 확보합니다.
 - **의의:** 단순 진단을 넘어선 **정밀 의료(Precision Medicine)**의 실현 가능성 제시.

4. 고찰 (Discussion): 경쟁 모델 디펜스 및 차별화

디펜스 논리 1: vs BrainLM (Spatial Fidelity & Resolution)

- **공격 포인트:** BrainLM은 대규모 학습을 했지만 ROI 기반이므로 정보 손실이 큼,.
- **방어 논리:** "BrainLM은 뇌를 '단어의 나열'로 단순화했지만, 뇌 질환의 병리는 **ROI 내부의 미세한 패턴**에서 시작된다. SwiFT v2는 **4D Voxel 기반** 학습을 통해 이를 보존했기에, '미래 예후 예측'이나 '미세 병변 탐지'에서 월등한 성능을 보인다."

디펜스 논리 2: vs NeuroSTORM (Connectivity vs Efficiency)

- **방어 논리:** "NeuroSTORM의 Mamba는 효율적이지만, 뇌의 핵심인 **전역적 연결성(Global Connectivity)**을 포착하는 데는 Attention이 더 강력하다. SwiFT v2는 **Factorized Attention**을 통해 효율성을 챙기면서도, **Hurst Exponent**가 증명한 듯 뇌의 장기적 문맥을 보존했다",.

디펜스 논리 3: vs Brain-JEPA (Generative Capability)

- **방어 논리:** "Brain-JEPA는 생성형 모델이 노이즈를 학습한다고 비판하지만, 우리의 **PSD 분석(3.Result-Part 2)**을 보라. 우리는 노이즈(White noise)가 아닌 **뇌의 신**

호($1/f$)만 완벽히 복원했다. 덕분에 생성형 모델의 장점인 **미래 상태 예측 (Forecasting)** 능력을 유지하면서도 노이즈 문제를 해결했다."

5. 결론 (Conclusion)

- "SwiFT v1이 '**4D fMRI Transformer의 시대**'를 열며 가능성을 증명했다면, SwiFT v2는 이를 완성하여 '**임상 신경과학을 위한 Universal Foundation Model**'의 표준을 제시한다."
- "우리는 뇌를 '언어'로 비유하는 것(BrainLM)을 넘어, 뇌를 '**물리적 실체(Physical Entity)**'로 다룸으로써 신경과학의 난제를 해결하고 데이터 빈곤에 시달리는 임상 연구를 가속화한다."